

Laporan Akhir Proyek Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-C
Ketua	Arya Bintang Fauzildan (24031554127)
Anggota 1	Ivan Andika Setyawan (24031554085)
Anggota 2	E.Adi Sforza Syahrul Ramadhan (24031554113)
URL Github	https://github.com/Fauzildan/UAS_ML_TEAM_7

Informasi Umum Proyek


Judul	Klasifikasi Jenis Sampah Berbasis EfficientNet-B0 dan Komparasi SVM-XGBoost untuk Mendukung Pengelolaan Sampah Perkotaan
Topik	Energi - Lingkungan/Pengelolaan Sampah
Pilihan Rumusan Masalah	3.3 Kurangnya Pengembangan Waste-to-Energy dari Sampah Kota dan Residu Biomassa
Revisi?	Ya / Tidak

Pendahuluan

Deskripsi Rumusan masalah	Pemanfaatan sampah kota sebagai sumber energi alternatif melalui skema waste-to-energi masih jauh dari potensi terbesarnya. TPA Benowo Surabaya, sebagai salah satu TPA terbesar di Indonesia, telah dilengkapi dengan teknologi Pembangkit Listrik Tenaga Sampah (PLTSA) baik dengan metode gasifikasi termokimia untuk sampah non-organik maupun fermentasi gas untuk sampah organik yang mampu mengolah hingga 1.000 ton sampah per hari menjadi energi listrik sebesar 12 MW. Namun, faktanya, volume sampah yang masuk mencapai 1.500-1.700 ton per hari, jauh melampaui kapasitas pengelolaan yang tersedia. Permasalahannya, tidak semua jenis sampah dapat digunakan sebagai bahan bakar secara langsung. Maka perlu dilakukan pemilahan sampah baik untuk produktivitas energi maupun untuk mengurangi emisi yang dihasilkan. Jenis sampah yang umumnya digunakan berupa sampah yang mudah terbakar seperti sampah dari sisa makanan yang sudah mengering, daun kering, potongan kayu, dan limbah kebun bisa digunakan untuk PLTSA dengan proses pembakaran atau biodigester. Sampah seperti plastik yang tidak bisa didaur ulang, kain sobekan, dan karet dapat dibakar pada suhu tinggi. Sementara itu, sampah limbah B3 (Bahan Berbahaya dan Beracun) tidak dapat diolah di PLTSA sehingga harus dipilah. Sementara itu, sampah seperti botol plastik dan kaca masih bisa didaur ulang sehingga memiliki nilai ekonomi yang tinggi. Salah satu akar permasalahan yang menghambat efektivitas sistem waste-to-energy ini adalah ketiadaan mekanisme pemilahan sampah yang cepat sebagai bentuk efisiensi waktu. Teknologi gasifikasi dan fermentasi di TPA Benowo membutuhkan input sampah yang sudah terpilah berdasarkan jenisnya agar dapat beroperasi secara optimal. Namun, pemilahan yang selama ini dilakukan secara manual terbukti tidak efisien dan tidak setara untuk volume sebesar ini dan akan terus meningkat seiring berjalannya hari. Permasalahan ini belum terselesaikan karena belum tersedianya sistem otomatis berbasis kecerdasan buatan (AI) yang mampu mengklasifikasikan jenis sampah
---------------------------	--



	<i>secara cepat dan akurat sebagai tahap awal dalam rantai pengelolaan waste-to-energy. Tantangan utama dalam membangun sistem tersebut, antara lain:</i> <i>1. Variasi visual antarjenis sampah yang tinggi dan overlap antarkelas seperti plastik dan kertas yang sulit dibedakan secara visual.</i> <i>2. Class imbalance pada dataset yang tersedia.</i> <i>3. Kompleksitas background gambar menyulitkan ekstraksi fitur secara presisi.</i>
Tujuan penelitian (Objectives)	<i>1. Membangun pipeline ekstraksi fitur visual dari citra sampah menggunakan EfficientNet-B0 sebagai feature extractor</i> <i>2. Menangani ketidakseimbangan kelas (class imbalance) pada dataset menggunakan teknik augmentasi data</i> <i>3. Melatih dan membandingkan performa classifier SVM dan XGBoost di atas fitur EfficientNet-B0</i> <i>4. Mengevaluasi performa model menggunakan metrik accuracy, precision, recall, F1-score, dan confusion matrix</i>
Metodologi	
Ringkasan dataset	<i>Dataset ini berisi kurang lebih 12.259 gambar (standardized_256) yang terbagi dalam 10 class dengan rincian</i> <i>1. Metal 930 gambar</i> <i>2. Glass 1736 gambar</i> <i>3. Biological 699 gambar</i> <i>4. Paper 1336 gambar</i> <i>5. Battery 756 gambar</i> <i>6. Trash 453 gambar</i> <i>7. Cardboard 1411 gambar</i> <i>8. Shoes 1499 gambar</i> <i>9. Clothes 1892 gambar</i> <i>10. Plastic 1597 gambar</i>

Sample Gambar Per Kelas Dataset Garbage Classification V2



	<i>Gambar 1. Sample Dataset</i>
Alur penelitian	Berikan ilustrasi (flowchart atau BPMN chart) yang meringkas proses pengolahan data untuk menyelesaikan permasalahan yang diangkat. Tuliskan deskripsi lengkap pada tiap langkah. <pre> graph TD Start([Mulai]) --> DataSet[/DataSet/] DataSet --> PreProcessing subgraph PreProcessing [Pre - Processing] direction TB A[Resize & normalisas] B[Train-test split] C[Augmentasi] end PreProcessing --> FE[Feature Extractor] FE --> Modeling subgraph Modeling [] direction TB D[Model SVM] E[Model XGboost] end Modeling --> Eval[Evaluasi] Eval --> End([Selesai]) </pre> <i>Gambar 1. Alur Penelitian</i> <i>Dataset</i> Load dataset yang berisi 10 class yaitu Metal, Glass, Biological, Paper, Battery, Trash, Cardboard, Shoes, Clothes, Plastic. <i>Pre-Processing</i> Dalam bagian pre-processing ada beberapa step, seperti Resize, yang awalnya dataset yang kami dapatkan berukuran 256 x 256 pixel menjadi 224 x 224 pixel, yang merupakan dimensi input standar arsitektur EfficientNet-B0. Setelah melalui tahap Resize, dataset dibagi menjadi data train dan test dengan rasio 80:20 menggunakan stratified split. Setelah mendapatkan data Train dan data Test selanjutnya Augmentasi data train untuk class minoritas <i>Feature Extractor</i> Ekstraksi fitur dilakukan menggunakan arsitektur EfficientNet-B0 pre-trained pada dataset ImageNet. Layer klasifikasi akhir dilepas dan bobot model frozen sehingga model berfungsi secara default sebagai feature extractor tanpa proses fine-tuning. Setiap gambar yang telah dipreproses dilewatkan melalui model ini untuk menghasilkan vektor fitur berdimensi 1280 yang merepresentasikan konten visual gambar abstrak. Hasil ekstraksi fitur disimpan dalam format .npy sebagai output akhir tahap preprocessing yang akan digunakan oleh classifier SVM dan XGBoost pada tahap modeling <i>Model</i> <i>SVM</i>

	Model SVM menggunakan beberapa parameter seperti kernel rbf dan gamma="scale" yang digunakan untuk menangani pola data non-linear secara fleksibel, parameter C=10.0 yang digunakan untuk meningkatkan akurasi klasifikasi pada data training, parameter class_weight="balanced" yang digunakan untuk mengatasi ketidakseimbangan jumlah sampel antar kelas, parameter probability=True dan random_state=42 yang digunakan untuk menghasilkan prediksi berupa skor probabilitas yang konsisten, serta parameter decision_function_shape="ovr" dan verbose=True yang digunakan untuk menangani klasifikasi multi-kelas sekaligus menampilkan proses pelatihan secara langsung. b. XGBoost Model XGBoost ini menggunakan beberapa parameter seperti n_estimators=100 dan learning_rate=0.1 yang digunakan untuk membangun 100 pohon keputusan secara bertahap dengan kecepatan belajar yang stabil, parameter max_depth=6 yang digunakan untuk membatasi kedalaman maksimum setiap pohon agar tidak terjadi overfitting, parameter objective="multi:softmax" dan num_class yang digunakan untuk menjalankan klasifikasi multi-kelas dengan output label kategori langsung, parameter eval_metric="mlogloss" yang digunakan untuk mengukur performa kerugian (loss) multispesifik selama pelatihan, serta parameter n_jobs=-1, random_state=42, dan callbacks yang digunakan untuk mempercepat proses komputasi menggunakan seluruh core CPU secara konsisten sekaligus menampilkan grafik kemajuan pelatihan (progress bar). 5. Evaluasi Untuk evaluasi menggunakan f1-score, accuracy, precision, recall untuk dibandingkan dengan model yang lain
Proses wrangling	Proses Wrangling meliputi 2 hal utama, yang pertama standardisasi ukuran gambar yang di mana dataset awal berukuran 256 x 256 diresize menjadi 224 x 224 sesuai dengan input standar EfficientNet-B0. Selanjutnya, yang kedua yaitu augmentasi gambar yang hanya diterapkan pada kelas minoritas di dalam data train dengan teknik augmentasi yang diterapkan meliputi rotasi 20 derajat, horizontal flip, pergeseran horizontal dan vertikal sebesar 10%, serta variasi kecerdasan dengan rentang 80% hingga 120%.
Proses rekayasa fitur	Rekayasa fitur dilakukan menggunakan pendekatan transfer learning dengan arsitektur EfficientNet-B0 yang sebelumnya telah dilatih menggunakan dataset ImageNet. Model ini sudah mengenal jutaan gambar dari berbagai kategori, serta model sudah memiliki kemampuan membaca dan memahami konten visual sebuah gambar dengan baik. Namun, pada proyek ini, EfficientNet-B0 tidak dilatih ulang, melainkan hanya digunakan sebagai pengekstrak fitur. Caranya adalah dengan melepas layer klasifikasi di bagian akhir model dan membekukan seluruh bobotnya. Dengan begitu, setiap gambar sampah yang dimasukkan ke dalam model akan menghasilkan vektor fitur berdimensi 1280 yang merepresentasikan karakteristik visual gambar tersebut seperti tekstur, warna, bentuk dan pola tepi. Pendekatan ini juga didukung dalam review komprehensif di BMC Medical Imaging yang menjelaskan bahwa pendekatan extractor hybrid yaitu membuang layer FC dan mengganti dengan classifier machine learning serta disini juga merupakan salah satu dari empat

	pendekatan transfer learning yang umum digunakan , dimana bobot lapisan konvolusional dibekukan selama proses ini seperti ada di gambar  <i>Gambar 2. 4 tipe Transfer Learning</i>
Temuan	1. <i>Class Imbalance yang signifikan, ditemukan ketidakseimbangan yang cukup besar antar kelas. Kelas “Clothes” mendominasi, sedangkan kelas “Trash” hanya memiliki 453 gambar dengan selisih lebih dari 4 kali lipat.</i> 2. <i>Perbedaan visual antarkelas tertentu terutama antara “Plastic” dan “Glass” yang sama-sama memiliki karakteristik transparan, serta “Paper” dan “Cardboard” yang memiliki tekstur serupa. Kondisi ini menjadi tantangan utama dalam proses klasifikasi karena model perlu belajar membedakan fitur yang sangat versatil.</i> 3. <i>Variasi background dan pencahayaan gambar dalam dataset menunjukkan variasi background dan kondisi pencahayaan yang cukup tinggi antar gambar dalam kelas yang sama. Hal ini mencerminkan kondisi dunia nyata di mana sampah dapat ditemukan dalam berbagai setting lingkungan.</i>
Hasil dan Pembahasan	
Hasil eksplorasi data	 <i>Gambar 3. Jumlah Data</i> <i>Problem dari dataset ini imbalanced yang cukup signifikan, sehingga dilakukan augmentasi untuk balancing. Augmentasi dilakukan setelah data displit dan hanya pada data train yang berisi 80% dari keseluruhan data.</i>

Setelah kedua Model dijalankan dengan parameter yang sudah dijelaskan di alur penelitian sehingga metrik yang dihasilkan sebagai berikut

Tabel 1. Metrik Evaluasi SVM

<u>Class</u>	<u>Precision</u>	<u>Recall</u>	<u>F1-Score</u>	<u>Support</u>
<u>Battery</u>	<u>0.97</u>	<u>0.97</u>	<u>0.97</u>	<u>151</u>
<u>Biological</u>	<u>0.98</u>	<u>0.97</u>	<u>0.97</u>	<u>140</u>
<u>Cardboard</u>	<u>0.96</u>	<u>0.93</u>	<u>0.94</u>	<u>282</u>
<u>Clothes</u>	<u>0.99</u>	<u>0.99</u>	<u>0.99</u>	<u>379</u>
<u>Glass</u>	<u>0.94</u>	<u>0.95</u>	<u>0.95</u>	<u>347</u>
<u>Metal</u>	<u>0.90</u>	<u>0.91</u>	<u>0.93</u>	<u>186</u>
<u>Paper</u>	<u>0.88</u>	<u>0.92</u>	<u>0.91</u>	<u>267</u>
<u>Plastic</u>	<u>0.93</u>	<u>0.86</u>	<u>0.87</u>	<u>319</u>
<u>Shoes</u>	<u>0.98</u>	<u>0.99</u>	<u>0.99</u>	<u>290</u>
<u>Trash</u>	<u>0.87</u>	<u>0.80</u>	<u>0.83</u>	<u>91</u>
<u>Accuracy</u>			<u>0.95</u>	<u>2452</u>
<u>Macro AVG</u>	<u>0.94</u>	<u>0.94</u>	<u>0.94</u>	<u>2452</u>
<u>Weighted AVG</u>	<u>0.95</u>	<u>0.95</u>	<u>0.95</u>	<u>2452</u>


Tabel 2. Metrik Evaluasi XGBoost

<u>Class</u>	<u>Precision</u>	<u>Recall</u>	<u>F1-Score</u>	<u>Support</u>
<u>Battery</u>	<u>0.96</u>	<u>0.93</u>	<u>0.94</u>	<u>151</u>
<u>Biological</u>	<u>0.98</u>	<u>0.94</u>	<u>0.96</u>	<u>140</u>
<u>Cardboard</u>	<u>0.92</u>	<u>0.90</u>	<u>0.91</u>	<u>282</u>
<u>Clothes</u>	<u>0.97</u>	<u>0.98</u>	<u>0.97</u>	<u>379</u>
<u>Glass</u>	<u>0.91</u>	<u>0.90</u>	<u>0.90</u>	<u>347</u>
<u>Metal</u>	<u>0.90</u>	<u>0.93</u>	<u>0.92</u>	<u>186</u>
<u>Paper</u>	<u>0.86</u>	<u>0.84</u>	<u>0.85</u>	<u>267</u>
<u>Plastic</u>	<u>0.88</u>	<u>0.86</u>	<u>0.87</u>	<u>319</u>
<u>Shoes</u>	<u>0.96</u>	<u>0.98</u>	<u>0.97</u>	<u>290</u>
<u>Trash</u>	<u>0.76</u>	<u>0.82</u>	<u>0.79</u>	<u>91</u>


<u>Accuracy</u>				<u>0.91</u>	<u>2452</u>
<u>Macro AVG</u>	<u>0.90</u>	<u>0.90</u>	<u>0.90</u>	<u>0.90</u>	<u>2452</u>
<u>Weighted AVG</u>	<u>0.91</u>	<u>0.91</u>	<u>0.91</u>	<u>0.91</u>	<u>2452</u>

Seperti yang dapat dilihat pada Tabel 1 dan Tabel 2, secara umum SVM lebih unggul dibandingkan dengan XGBoost. Meskipun begitu, gap antara kedua model tidak terpaut jauh, di mana Macro AVG F1 score hanya 4%. SVM mendapat 94%, sedangkan XGBoost mendapat 90%.

Rentang pada tiap kelas pada SVM adalah 83% – 99%, dengan prediksi F1-score terendah pada kelas “Trash”. Sebaliknya nilai tertinggi pada kelas “Clothes” dan “Shoes” dengan F1-Score 99%. Model XGBoost juga mengalami pola yang sama dengan rentang 79%–97%. Maka, kedua model kesulitan terhadap kelas “Trash” ini diakibatkan oleh citra pada kelas ini yang sangat beragam, mulai dari sikat gigi hingga ceceran kertas. Sebaliknya, kedua model dapat mengenali dengan baik kelas “Clothes” dan “Shoes”.



Gambar 4. Confusion Matrix SVM



Gambar 5. Confusion matrix XGBoost

Berdasarkan analisis confusion matrix pada Gambar 4 dan 5, SVM secara konsisten menunjukkan keunggulan dibandingkan dengan XGBoost. Hal ini terlihat dari penurunan FP dan FN di hampir seluruh kelas, yang mengindikasikan kemampuan generalisasi SVM lebih baik dalam membedakan kategori sampah yang memiliki kemiripan visual.

Kelas “Cardboard” menjadi bukti paling nyata, di mana FP XGBoost mencapai 41, turun menjadi hanya 11 pada SVM, sejalan dengan F1-Score “Cardboard” yang meningkat. Kelas clothes dan shoes tampil konsisten kuat pada kedua model, mengonfirmasi bahwa kedua kelas ini memiliki fitur visual yang paling khas dan tidak ambigu. Sementara itu, kelas trash tetap menjadi bottleneck di kedua model dengan FN dan FP yang relatif tinggi

Secara keseluruhan, error rate pada SVM yang lebih rendah dibandingkan dengan XGBoost memperkuat bahwa SVM lebih robust dibandingkan dengan XGBoost dalam konteks data ini.

Kesimpulan dan Saran

Kesimpulan

Proyek ini berhasil membangun sistem klasifikasi jenis sampah otomatis menggunakan pendekatan transfer learning berbasis EfficientNet-B0 sebagai pengekstrak fitur, dikombinasikan dengan dua classifier, yaitu SVM dan XGBoost. Sistem ini dikembangkan sebagai solusi atas keterbatasan pemilahan sampah manual di TPA Benowo Surabaya yang tidak mampu mengimbangi volume sampah sebesar 1500 - 1700 ton per hari

Berdasarkan hasil eksperimen terhadap 10 kelas sampah dengan total 2452 data uji, diperoleh beberapa temuan sebagai berikut

1. Svm lebih unggul dibanding XGBoost dalam mengklasifikasikan fitur berdimensi tinggi hasil EfficientNet-B0 dengan akurasi keseluruhan 95%

	dibanding XGBoost yang mencapai 91%. Meski demikian selisih dari kedua model hanya 4% sehingga keduanya tetap layak dipertimbangkan untuk implementasi nyata 2. Kedua model masih kesulitan terhadap kelas “Trash” ini karena citra pada kelas ini yang sangat beragam, mulai dari sikat gigi hingga ceceran kertas. 3. EfficientNet-B0 sebagai feature extractor tanpa fine-tuning sudah mampu menghasilkan representasi fitur yang cukup kuat untuk mencapai akurasi tinggi, ini membuktikan bahwa pendekatan transfer learning efisien secara komputasi sekaligus efektif untuk klasifikasi sampah
Saran	Penelitian dapat dikembangkan dengan cara sebagai berikut: 1. Mengembangkan pipeline sehingga dapat berjalan secara real-time, pipeline pada penelitian ini masih terbatas pada pengenalan objek satu 2. Penambahan dataset berdasarkan kondisi lapangan pada penelitian ini didapatkan melalui Kaggle. Gambar secara visual masih bagus. Bukan barang yang telah dibuang atau tidak terpakai 3. Mengganti kelas atau menyesuaikan kelas: apakah sampah dapat masuk ke insinerator? Atau perlu penanganan khusus ? Atau tidak bisa sama sekali.
Daftar Pustaka	
Daftar Pustaka	Nisa, Iffa Zainan, et al. “KLASIFIKASI CITRA SAMPAH MENGGUNAKAN SUPPORT VECTOR MACHINE DENGAN EKSTRAKSI FITUR GRAY LEVEL CO-OCCURRENCE MATRIX DAN COLOR MOMENTS.” <i>Jurnal Teknologi Informasi dan Ilmu Komputer</i>, vol. 9, no. 5, 2022, pp. 921-930, https://jtiik.ub.ac.id/index.php/jtiik/article/view/4868/pdf. Akbar, A. M., Basri, M., & Basri. (2025, 02 21). Implementasi Machine Learning Menggunakan Algoritma Klasifikasi untuk Mendeteksi Jenis Sampah. <i>Jurnal Publikasi Manajemen Informatika</i>, 3(3), 152-161. https://doi.org/10.55606/jupumi.v3i3.3751 Kim, H. E., Linan, A. C., Santhaman, N., Jannesari, M., Maros, M. E., & Ganslandt, T. (April, 13). Transfer learning for medical image classification: a literature review. <i>BMC Medical Image</i>, 22. https://doi.org/10.1186/s12880-022-00793-7 Nguyen, N.-B.-Q., Do, T.-M., Phan, C.-T., & Phan*, T.-T.-H. (2025, Oktober 22). <i>Towards Accurate and Efficient Waste Image Classification: A Hybrid Deep</i>

	<i>Learning and Machine Learning Approach.</i> Arxiv. https://arxiv.org/pdf/2510.21833
--	---